



***Universidad Tecnológica
de El Salvador***

**UNIVERSIDAD TECNOLÓGICA DE EL SALVADOR
FACULTAD DE INFORMATICA Y CIENCIAS APLICADAS**

Alumno:

José Ricardo Miguel Garay

Carnet:

25-0723-2022

Docente:

Jorge Machado

Materia:

Técnica de producción industrial de software II 01 01-2026

Actividad:

Caso práctico InnovaSoft Analytics

Fecha de entrega:

12 de mayo del 2026

Introducción

En la actualidad, las organizaciones orientadas al análisis de datos requieren comprender cómo distintos factores socioeconómicos influyen en el desarrollo profesional y en la valoración de diferentes ocupaciones dentro de la sociedad. En este contexto, el análisis de datos se convierte en una herramienta fundamental para apoyar la toma de decisiones estratégicas relacionadas con la formación académica, la gestión del talento y la planificación organizacional.

El presente caso práctico se desarrolló utilizando el dataset denominado `Prestige_modificado.csv`, el cual contiene información relacionada con distintas ocupaciones, incluyendo variables como nivel educativo promedio, ingresos, porcentaje de mujeres en la ocupación, prestigio ocupacional, código censal y tipo de ocupación. Estas variables permiten identificar patrones y relaciones relevantes entre factores educativos, económicos y sociales asociados al prestigio laboral.

Para el desarrollo de la actividad, se asumió el rol de analista de datos dentro de una empresa ficticia llamada InnovaSoft Analytics, encargada de apoyar a una dirección académica o empresarial en la interpretación de datos ocupacionales. El propósito principal consiste en diseñar una propuesta orientada al fortalecimiento de la formación de talento en áreas técnicas y de gestión de software, utilizando técnicas básicas de minería de datos y análisis exploratorio.

A lo largo del análisis se aplicaron procesos de preparación e inspección del dataset, análisis de correlación, visualización de datos y técnicas de agrupación mediante el algoritmo K-Means. Estas herramientas permitieron identificar relaciones significativas

entre variables, reconocer patrones ocupacionales y segmentar grupos con características similares. Asimismo, el proyecto busca simular un flujo de trabajo analítico similar al utilizado en entornos reales de Business Intelligence, donde cada etapa del análisis debe ser estructurada, reproducible e interpretable para apoyar la toma de decisiones basada en datos.

Objetivos

Objetivo General:

Analizar la relación entre variables socioeconómicas y el prestigio ocupacional mediante técnicas de análisis de datos y clusterización en Python, con el propósito de identificar patrones que contribuyan a la interpretación de ocupaciones y al fortalecimiento de la formación de talento en áreas técnicas y de gestión de software dentro del contexto de la empresa ficticia InnovaSoft Analytics.

Objetivos Específicos:


1. Identificar las características principales del dataset `Prestige_modificado.csv` mediante procesos de carga, inspección y validación de datos en Python.
2. Examinar la relación existente entre variables como educación, ingresos, participación de mujeres y prestigio ocupacional utilizando análisis de correlación.
3. Visualizar patrones y tendencias entre las variables del dataset a través de gráficas de dispersión que faciliten la interpretación de los resultados.
4. Aplicar técnicas de agrupación utilizando el algoritmo K-Means para segmentar ocupaciones con características similares.

Descripción del Dataset

Para el desarrollo del presente caso práctico se utilizó el dataset denominado Prestige_modificado.csv, el cual contiene información relacionada con distintas ocupaciones y variables socioeconómicas asociadas al prestigio ocupacional. Este conjunto de datos fue empleado con el propósito de analizar patrones existentes entre factores educativos, económicos y sociales, permitiendo aplicar técnicas de análisis exploratorio y agrupación de datos dentro de un entorno de Business Intelligence.

El dataset está compuesto por 102 registros y 7 variables principales, las cuales representan características relevantes de diferentes ocupaciones. Cada registro corresponde a una ocupación específica y contiene información cuantitativa y categórica que facilita el estudio comparativo entre profesiones y actividades laborales.

Las variables incluidas en el dataset son las siguientes:



	occupation	education	income	women	prestige	census	type_num
0	gov.administrators	13.11	12351	11.16	68.8	1113	1
1	general.managers	12.26	25879	4.02	69.1	1130	1
2	accountants	12.77	9271	15.70	63.4	1171	1
3	purchasing.officers	11.42	8865	9.11	56.8	1175	1
4	chemists	14.62	8403	11.68	73.5	2111	1

Próximos pasos: [Generar código con df](#) [New interactive sheet](#)

Desde una perspectiva analítica, las variables education, income, women y prestige representan los elementos principales para el análisis estadístico y de correlación, ya que permiten identificar posibles relaciones entre formación académica, nivel económico, composición de género y valoración social de las ocupaciones.

Por otra parte, variables como `census` y `type_num` funcionan como elementos de clasificación y categorización, facilitando procesos de agrupación mediante técnicas de minería de datos como el algoritmo K-Means. Estas variables permiten segmentar ocupaciones con características similares y detectar patrones relevantes dentro del conjunto de datos.

El dataset utilizado presenta características adecuadas para el desarrollo de análisis exploratorios y modelos básicos de clusterización, debido a que contiene variables numéricas comparables y suficientes registros para identificar tendencias generales. Asimismo, la diversidad de ocupaciones incluidas permite generar interpretaciones relacionadas con educación, ingresos y prestigio ocupacional en distintos contextos laborales.

Finalmente, este conjunto de datos resulta apropiado para simular escenarios de análisis empresarial y académico, donde la interpretación de información ocupacional puede contribuir a la toma de decisiones orientadas al fortalecimiento de competencias técnicas y de gestión dentro de organizaciones enfocadas en tecnología y análisis de datos.

Preparacion de datos en Phyton

Como parte inicial del proceso analítico, se realizó la preparación e inspección del dataset utilizando el entorno Google Colab y el lenguaje de programación Python. Esta etapa resulta fundamental dentro de cualquier proyecto de análisis de datos, ya que permite verificar la calidad, estructura y consistencia de la información antes de aplicar técnicas estadísticas o modelos de minería de datos.

En primer lugar, se importaron librerías especializadas para el procesamiento y análisis de información, entre las cuales destacan pandas para la manipulación de datos, matplotlib y seaborn para la visualización gráfica, y scikit-learn para la implementación de técnicas de clusterización mediante K-Means.

Posteriormente, se procedió a cargar el dataset `Prestige_modificado.csv` desde un repositorio en línea alojado en GitHub, utilizando la función `read_csv()` de la librería pandas. Una vez cargada la información, se realizó una inspección inicial de los datos con el propósito de verificar la correcta lectura de registros y columnas.

Durante esta fase se aplicaron funciones como `head()`, `shape()` e `info()`, las cuales permitieron identificar la cantidad de registros, el número de variables y los tipos de datos presentes en el dataset. De igual manera, se utilizó la función `describe()` para obtener estadísticas descriptivas relacionadas con variables numéricas como educación, ingresos, porcentaje de mujeres y prestigio ocupacional.

El análisis descriptivo permitió observar medidas como promedio, desviación estándar, valores mínimos y máximos, proporcionando una visión general sobre el

comportamiento de los datos y facilitando la detección de posibles anomalías o inconsistencias.

Asimismo, esta etapa de preparación de datos fue importante para garantizar que las variables numéricas utilizadas posteriormente en el análisis de correlación y clusterización fueran adecuadas para el procesamiento estadístico. La correcta organización y validación del dataset permitió desarrollar las siguientes fases del proyecto de manera estructurada y coherente.

Finalmente, la preparación de datos constituye una de las etapas más importantes dentro de los procesos de Business Intelligence y minería de datos, debido a que la calidad de los resultados obtenidos depende directamente de la consistencia y confiabilidad de la información analizada.

Análisis de correlación e interpretación

Como parte del análisis exploratorio de datos, se realizó un estudio de correlación entre las variables numéricas del dataset con el propósito de identificar posibles relaciones entre factores socioeconómicos y el prestigio ocupacional. Para ello, se utilizó la matriz de correlación de Pearson mediante las funciones proporcionadas por la librería pandas, complementando posteriormente el análisis con visualizaciones gráficas.

La correlación permite medir el grado de relación existente entre dos variables numéricas, tomando valores entre -1 y 1. Los valores cercanos a 1 indican una relación positiva fuerte, los valores cercanos a -1 representan una relación negativa fuerte, mientras que valores próximos a 0 sugieren una relación débil o inexistente.

Los resultados obtenidos evidenciaron que la variable education presentó la correlación positiva más alta con prestige, alcanzando aproximadamente un valor de 0.85. Este resultado sugiere que las ocupaciones que requieren mayores niveles educativos tienden a poseer un mayor prestigio ocupacional. Desde una perspectiva académica y empresarial, este comportamiento resulta coherente, ya que profesiones con formación especializada suelen estar asociadas con una mayor valoración social y profesional.

De igual manera, la variable income mostró una correlación positiva considerable con prestige, con un valor cercano a 0.71. Esto indica que las ocupaciones con mayores ingresos generalmente también presentan niveles más altos de prestigio. Sin embargo, la correlación no es perfecta, lo cual evidencia que el ingreso económico no es el único factor que influye en la percepción del prestigio ocupacional.

Por otra parte, la variable women presentó una correlación negativa débil con respecto al prestigio ocupacional. Esto significa que dentro del conjunto de datos analizado no existe una relación fuerte entre el porcentaje de participación femenina y el nivel de prestigio de las ocupaciones. Este resultado debe interpretarse con precaución, ya que una correlación baja no implica necesariamente ausencia de factores sociales o estructurales relacionados con género.

Asimismo, las variables census y type_num reflejaron correlaciones negativas moderadas con prestige, debido principalmente a que funcionan como variables de clasificación y categorización más que como indicadores socioeconómicos directos.

Para complementar el análisis estadístico, se desarrollaron gráficas de dispersión entre las variables education y prestige, así como entre income y prestige. Estas

visualizaciones permitieron observar de manera más clara las tendencias positivas identificadas en la matriz de correlación.

En la gráfica correspondiente a educación y prestigio se observó una tendencia ascendente relativamente marcada, lo que refuerza la existencia de una relación positiva significativa entre ambas variables. De manera similar, la gráfica de ingresos y prestigio mostró un patrón ascendente, aunque con una mayor dispersión entre los datos, indicando que algunos casos particulares pueden diferir de la tendencia general.

Finalmente, el análisis de correlación permitió identificar patrones relevantes dentro del dataset y proporcionó una base sólida para las siguientes etapas del proyecto, especialmente en la aplicación de técnicas de clusterización. Asimismo, este tipo de análisis resulta de gran utilidad dentro de entornos de Business Intelligence, ya que facilita la comprensión de relaciones entre variables y contribuye a la toma de decisiones basada en evidencia estadística.

Análisis de agrupación con K-Means

Como parte de las técnicas de minería de datos aplicadas en el presente caso práctico, se desarrolló un análisis de agrupación utilizando el algoritmo K-Means. El propósito de esta etapa consistió en segmentar las ocupaciones del dataset en grupos con características similares, permitiendo identificar patrones relacionados con educación, ingresos, participación femenina y prestigio ocupacional.

El algoritmo K-Means es una técnica de aprendizaje no supervisado ampliamente utilizada en procesos de clusterización. Su funcionamiento se basa en dividir un conjunto de datos en diferentes grupos denominados clústeres, donde los elementos pertenecientes a

un mismo grupo presentan características más similares entre sí en comparación con los elementos de otros grupos.

Para la implementación del modelo, se seleccionaron variables numéricas relevantes dentro del dataset, específicamente: education, income, women, Prestige, type_num.

Estas variables fueron consideradas debido a su importancia dentro del análisis socioeconómico y ocupacional desarrollado durante el proyecto.

Antes de aplicar el algoritmo K-Means, se realizó un proceso de normalización de datos utilizando StandardScaler de la librería scikit-learn. Este procedimiento fue necesario debido a que las variables utilizadas poseen escalas diferentes, especialmente en el caso de los ingresos económicos, los cuales presentan valores considerablemente mayores en comparación con otras variables. La normalización permitió evitar que una variable tuviera un peso excesivo sobre el modelo de agrupación.

Posteriormente, se ejecutó el algoritmo K-Means utilizando inicialmente una configuración de 4 clústeres. Como resultado, el modelo logró segmentar las ocupaciones en grupos con características diferenciadas, permitiendo identificar patrones ocupacionales específicos.

El análisis de centroides evidenció la existencia de grupos asociados a distintos niveles de educación, ingresos y prestigio. Algunos clústeres presentaron valores altos en educación e ingresos, acompañados de niveles elevados de prestigio ocupacional, lo que puede relacionarse con profesiones especializadas o de carácter profesional. Por otra parte, también se identificaron grupos con menores niveles educativos e ingresos más bajos, asociados a ocupaciones con menor prestigio relativo.

Asimismo, se observaron diferencias importantes en la participación femenina dentro de ciertos grupos, lo que permitió identificar variaciones en la composición ocupacional según el tipo de profesión analizada.

La clusterización realizada mediante K-Means permitió transformar datos numéricos en segmentos interpretables, facilitando la identificación de patrones ocultos dentro del conjunto de datos. Desde una perspectiva de Business Intelligence, este tipo de análisis resulta especialmente útil para apoyar procesos de toma de decisiones, clasificación de perfiles ocupacionales y diseño de estrategias relacionadas con formación académica y gestión del talento.

Finalmente, la aplicación de técnicas de agrupación permitió complementar el análisis exploratorio realizado previamente, proporcionando una visión más estructurada sobre la distribución y comportamiento de las ocupaciones presentes en el dataset analizado.

Comparación entre modelos de 4 y 5 clústeres

Con el propósito de obtener una segmentación más adecuada de las ocupaciones presentes en el dataset, se realizaron pruebas utilizando modelos de agrupación K-Means con 4 y 5 clústeres. La comparación entre ambos modelos permitió evaluar cuál de las configuraciones representaba de mejor manera la estructura de los datos y facilitaba una interpretación más clara de los grupos ocupacionales identificados.

El modelo de 4 clústeres presentó una segmentación general adecuada, permitiendo diferenciar grupos relacionados con distintos niveles de educación, ingresos y prestigio ocupacional. Esta configuración generó agrupaciones relativamente equilibradas y fáciles

de interpretar, identificando categorías generales de ocupaciones con características similares.

Sin embargo, al aplicar el modelo de 5 clústeres se observó una segmentación más detallada de los datos. La incorporación de un clúster adicional permitió separar ocupaciones que, aunque compartían ciertas similitudes, presentaban diferencias relevantes en variables como ingresos, nivel educativo o prestigio. Esto facilitó una interpretación más específica de determinados grupos ocupacionales.

A partir del análisis de centroides, se identificó que algunos clústeres representaban ocupaciones con altos niveles educativos y elevados ingresos económicos, asociados también con mayores niveles de prestigio ocupacional. En contraste, otros grupos reflejaban ocupaciones con menor especialización académica y menores ingresos, lo que se relacionó con niveles más bajos de prestigio.

El modelo de 5 clústeres permitió observar con mayor claridad estas diferencias internas, generando una segmentación más precisa y descriptiva. No obstante, el aumento en el número de grupos también incrementó ligeramente la complejidad interpretativa del modelo.

Desde una perspectiva analítica, ambos modelos resultaron funcionales y coherentes para el tipo de datos utilizado. Sin embargo, el modelo de 5 clústeres ofreció una representación más detallada de la diversidad ocupacional presente en el dataset, permitiendo identificar patrones más específicos entre las variables analizadas.

Por esta razón, se considera que el modelo de 5 clústeres proporciona una mejor interpretación para el presente caso práctico, ya que logra una segmentación más precisa de

las ocupaciones sin perder coherencia en la interpretación de los grupos obtenidos. Además, esta configuración facilita un análisis más completo de perfiles ocupacionales que podrían resultar relevantes en procesos de planificación académica, análisis organizacional o gestión de talento dentro de entornos empresariales orientados al análisis de datos.

Hallazgos principales

A partir del análisis realizado sobre el dataset `Prestige_modificado.csv`, fue posible identificar diversos patrones y relaciones relevantes entre las variables socioeconómicas y el prestigio ocupacional. Los resultados obtenidos mediante análisis de correlación, visualización de datos y técnicas de clusterización permitieron generar hallazgos importantes para la interpretación de perfiles ocupacionales dentro del contexto planteado.

Uno de los principales hallazgos fue la existencia de una relación positiva significativa entre el nivel educativo y el prestigio ocupacional. La variable `education` presentó la correlación más alta con respecto a `prestige`, indicando que las ocupaciones que requieren mayores niveles de formación académica tienden a poseer una mayor valoración social y profesional.

Asimismo, se identificó que los ingresos económicos también mantienen una relación positiva considerable con el prestigio ocupacional. Las ocupaciones con mayores ingresos promedio suelen estar asociadas a niveles más altos de prestigio, aunque el análisis evidenció que el ingreso no es el único factor determinante dentro de la valoración ocupacional.

Las gráficas de dispersión permitieron confirmar visualmente estas tendencias, mostrando patrones ascendentes entre educación y prestigio, así como entre ingresos y

prestigio. Esto permitió validar de manera gráfica los resultados obtenidos en la matriz de correlación.

Por otra parte, el análisis de agrupación mediante K-Means permitió segmentar las ocupaciones en grupos con características similares. Los modelos aplicados lograron identificar clústeres asociados a ocupaciones de alto prestigio y especialización, así como grupos relacionados con menores niveles educativos, menores ingresos y menor valoración ocupacional.

Dentro de los clústeres obtenidos, se observaron grupos ocupacionales caracterizados por altos niveles educativos e ingresos elevados, los cuales también presentaron los valores más altos de prestigio. De igual manera, se identificaron grupos con menor nivel educativo y menores ingresos económicos, asociados a ocupaciones con prestigio relativamente bajo.

Otro hallazgo relevante fue la presencia de diferencias en la participación femenina entre ciertos grupos ocupacionales. Algunos clústeres mostraron porcentajes significativamente más altos de participación de mujeres, evidenciando variaciones importantes en la composición de determinadas ocupaciones.

Finalmente, el análisis demostró que las técnicas de minería de datos y Business Intelligence pueden contribuir significativamente a la interpretación de información ocupacional, facilitando la identificación de patrones útiles para procesos de análisis organizacional, formación académica y toma de decisiones basada en datos.

Conclusión y recomendaciones

El análisis realizado sobre el dataset `Prestige_modificado.csv` permitió identificar relaciones importantes entre variables socioeconómicas y el prestigio ocupacional. Los resultados evidenciaron que variables como educación e ingresos presentan una relación positiva con el nivel de prestigio de las ocupaciones, indicando que las profesiones con mayor formación académica y mejores ingresos tienden a ser más valoradas socialmente.

Asimismo, la aplicación del algoritmo K-Means permitió segmentar las ocupaciones en grupos con características similares, facilitando la identificación de perfiles ocupacionales diferenciados según educación, ingresos, participación femenina y prestigio. La comparación entre los modelos de 4 y 5 clústeres permitió concluir que el modelo de 5 grupos ofrece una segmentación más detallada y precisa de los datos.

Desde una perspectiva académica, este caso práctico permitió fortalecer conocimientos relacionados con análisis de datos, visualización, correlación y técnicas básicas de minería de datos utilizando Python y Google Colab.

Como recomendación, sería conveniente trabajar en futuros análisis con datasets más amplios e incorporar nuevas variables que permitan obtener interpretaciones más completas sobre las ocupaciones y sus características socioeconómicas. Además, podrían aplicarse técnicas adicionales de análisis predictivo y aprendizaje automático para ampliar el alcance del estudio.

Anexos

carga y preparación de datos.

Actividad 1. Preparación e inspección inicial del dataset

```
url = "https://raw.githubusercontent.com/jRicardo2003/CasoPractico/refs/heads/main/data/Prestige_modificado.csv"
df = pd.read_csv(url, sep=';')
df.head()
```

	occupation	education	income	women	prestige	census	type_num
0	gov.administrators	13.11	12351	11.16	68.8	1113	1
1	general.managers	12.26	25879	4.02	69.1	1130	1
2	accountants	12.77	9271	15.70	63.4	1171	1
3	purchasing.officers	11.42	8865	9.11	56.8	1175	1
4	chemists	14.62	8403	11.68	73.5	2111	1

Próximos pasos: [Generar código con df](#) [New interactive sheet](#)

```
print(df.head())
```

	occupation;education;income;women;prestige;census;type_num
0	gov.administrators;13.11;12351;11.16;68.8;1113;1
1	general.managers;12.26;25879;4.02;69.1;1130;1
2	accountants;12.77;9271;15.7;63.4;1171;1
3	purchasing.officers;11.42;8865;9.11;56.8;1175;1
4	chemists;14.62;8403;11.68;73.5;2111;1

```
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 102 entries, 0 to 101
Data columns (total 1 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   occupation;education;income;women;prestige;census;type_num  102 non-null   object
dtypes: object(1)
memory usage: 948.0+ bytes
None
```

Estadística descriptiva:

```
print(df.describe())
```

	occupation;education;income;women;prestige;census;type_num
count	102
unique	102
top	gov.administrators;13.11;12351;11.16;68.8;1113;1
freq	1

Matriz de correlación:


```
variables_numericas = df.select_dtypes(include=['int64', 'float64'])
matriz_correlacion = variables_numericas.corr()

print(matriz_correlacion.round(3))
print(matriz_correlacion['prestige'].sort_values(ascending=False).round(3))
```

	education	income	women	prestige	census	type_num
education	1.000	0.578	0.062	0.850	-0.823	-0.382
income	0.578	1.000	-0.441	0.715	-0.361	-0.368
women	0.062	-0.441	1.000	-0.118	-0.227	0.251
prestige	0.850	0.715	-0.118	1.000	-0.635	-0.465
census	-0.823	-0.361	-0.227	-0.635	1.000	0.288
type_num	-0.382	-0.368	0.251	-0.465	0.288	1.000

```
prestige
education    1.000
income       0.850
women        0.715
type_num     -0.118
census       -0.465
Name: prestige, dtype: float64
```

Grafica de dispersión: Education vs Prestige



Grafica de dispersión: Income vs Prestige



Clusterización K-Means.

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

columnas_cluster = ['education', 'income', 'women', 'prestige', 'type_num']
X = df[columnas_cluster].copy()

escalador = StandardScaler()
X_escalado = escalador.fit_transform(X)

modelo_k4 = KMeans(n_clusters=4, random_state=42, n_init=10)
df['Cluster_4'] = modelo_k4.fit_predict(X_escalado)

modelo_k5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df['Cluster_5'] = modelo_k5.fit_predict(X_escalado)

print(df.groupby('Cluster_4')[columnas_cluster].mean().round(2))
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))
```

Tabla de centroides:

...	education	income	women	prestige	type_num
Cluster_4					
0	13.59	7329.35	36.35	63.33	0.95
1	8.82	5878.74	9.60	37.26	2.09
2	10.12	3545.04	74.16	37.76	2.57
3	14.69	15746.83	6.00	74.23	1.00
	education	income	women	prestige	type_num
Cluster_5					
0	10.94	3909.12	73.76	41.50	2.88
1	9.31	6922.03	5.84	42.18	2.25
2	13.59	7329.35	36.35	63.33	0.95
3	7.78	3327.48	34.10	26.87	1.71
4	14.69	15746.83	6.00	74.23	1.00